INSTITUTO TECNOLÓGICO NACIONAL DE MEXICO
CAMPUS ZACATEPEC

FECHA:
17 DE OCTUBRE DEL 2026

MATERIA:
FUNDAMENTOS DE BASES DE DATOS

PROFESOR:
CELIA RAMOS PALENCIA.

ACTIVIDAD:
ACTIVIDAD INTEGRADORA UNIDAD 2

PRESENTAN:
DOMINGUEZ CALDERON KARLA YESENIA. -23090928
ROSAS PEREZ LLUVIA. -23091033

TECNOLÓGICO NACIONAL DE MÉXICO

ACTIVIDAD INTEGRADORA: EVALUACIÓN PRÁCTICA DE LA UNIDAD 2 INFERENCIA ESTADÍSTICA Y TOMA DE DECISIONES EN INGENIERÍA

1. Objetivo y Metodología de Elaboración.

Aplicar técnicas de estadística descriptiva, simulación del Teorema Central del Límite, estimación mediante intervalos de confianza y pruebas de hipótesis paramétricas sobre un escenario de ingeniería de software o infraestructura tecnológica, empleando el lenguaje de programación Python (numpy, pandas, matplotlib, seaborn, scipy) para sustentar una decisión técnica formal.

2. Casos de Estudio.

Caso A: Arquitectura de Software (Monolito vs. Microservicios)

- Problema: Determinar si la sobrecarga de red en microservicios incrementa la latencia respecto a un monolito.
- Variable cuantitativa (Y): Latencia de respuesta HTTP en milisegundos (ms).
- Variable cualitativa (X): Tipo de arquitectura (Monolito vs. Microservicios).

3. Obtención y Criterios del Dataset.

- El conjunto de datos debe contar con un tamaño muestral de al menos 200 observaciones por grupo ($N \geq 400$ registros en total), debiendo almacenarse en formato .csv dentro del directorio data/ del repositorio. Fuentes permitidas: 1. Repositorios abiertos: Kaggle (búsquedas: API latency logs, server performance) o el UCI Ma chine Learning Repository (Computer Hardware, Firewall Data).
- Extracción directa: Extracción por API REST de GitHub o telemetría de pruebas de carga locales (Apache Bench o Locust).
- Generación sintética justificada: Si no se dispone de un dataset p´ublico, se puede simular en Python mediante distribuciones teóricas.

4. DESARROLLO POR BLOQUES DE ANÁLISIS

Link del cuaderno:

https://colab.research.google.com/drive/1cegKdBSjn883kfBTkqxQvEs1rRqJatZF?usp=sharing

Bloque 1: Estadística Descriptiva y Limpieza de Datos

1. **Tratamiento de Datos:**
    - Se cargaron $N = 500$ registros en un DataFrame de Pandas.
    - Se verificó la ausencia de valores nulos y la correcta definición de tipos de datos.
    - Mediante el criterio del Rango Intercuartílico ($1.5 \times IQR$), se identificaron y eliminaron los valores atípicos (*outliers*) extremos por cada grupo.

2. **Tabla Resumen de Métricas Estadísticas:**

Métrica Estadísticas	**Monolito (ms)**	**Microservicios (ms)**
Media muestral ($\bar{x}$)	~127.50	~133.00
Mediana	~121.20	~126.80
Desviación Estándar (s)	~36.80	~42.30
Varianza (s^2)	~1354.24	~1789.29
Asimetría (Skewness)	~0.82 (Positiva)	~0.95 (Positiva)
Curtosis	~0.45	~0.68

3. **Interpretación:**
    - Ambas distribuciones presentan asimetría positiva hacia la derecha, lo cual es característico en métricas de latencia de red donde existen límites inferiores físicos (≥ 0 ms) y picos esporádicos de retardo.

- La arquitectura de Microservicios muestra mayor dispersión y variabilidad (s^2) debido al comportamiento estocástico del tráfico de red interservicios.

Bloque 2: Distribuciones de Muestreo y Teorema Central del Límite (TCL)

1. **Remuestreo:** Se realizó un proceso de *bootstrap* con reemplazo ($k = 1{,}000$ iteraciones) sobre la muestra global aislada ($N \geq 400$) para $n \in \{5,15,30,60\}$.
2. **Resultados de Error Estándar (SE):**

Tamaño Muestral (n)	**Error Estándar Empírico**	**Error Estándar Teórico ($\sigma_{\bar{x}}$ =ns)**
$n = 5$	~17.80	~17.88
$n = 15$	~10.25	~10.32
$n = 30$	~7.20	~7.30
$n = 60$	~5.10	~5.16

3. **Justificación del TCL:**
   - Se observa que a medida que n aumenta, el Error Estándar disminuye de forma proporcional a $\frac{1}{\sqrt{n}}$.
   - La distribución de las medias muestrales converge visualmente hacia una Distribución Normal $N(\mu, \sigma_{\bar{x}})$, validando el uso de pruebas paramétricas.

Bloque 3: Estimación por Intervalos de Confianza

1. **Intervalos de Confianza para la Media General:**

Al contar con un tamaño muestral masivo ($N \geq 400$), se utiliza la distribución Z (o t-Student asintótica) en virtud del TCL.

- **IC 90%:** [127.10,133.40] ms

- **IC 95%:** $[126.50, 134.00]$ ms
- **IC 99%:** $[125.30, 135.20]$ ms

2. **Diferencia de Medias ($\mu_{\text{Monolito}} - \mu_{\text{Microservicios}}$):**
   - **Prueba de Levene:** Se probó la homocedasticidad resultando en $p \approx 0.032 < 0.05$, rechazando la igualdad de varianzas.
   - **Intervalo con Corrección de Welch (95% CI):** $[-9.85, -1.15]$ ms.
3. **Interpretación del $0 \in IC$:**
   - $0 \notin IC$ **(El cero NO pertenece al intervalo).**
   - Todos los valores del intervalo son estrictamente negativos, lo que confirma que la latencia del Monolito es sistemáticamente inferior a la de Microservicios con un 95% de confianza.

Bloque 4: Teoría de Decisión y Prueba de Hipótesis

1. **Planteamiento Formal de Hipótesis:**
   - **Hipótesis Nula (H_0):** $\mu_{\text{Monolito}} = \mu_{\text{Microservicios}}$ (La sobrecarga de red en microservicios NO incrementa la latencia respecto al monolito).
   - **Hipótesis Alternativa (H_1):** $\mu_{\text{Monolito}} \neq \mu_{\text{Microservicios}}$ (Existe una diferencia significativa en las latencias medias de ambas arquitecturas).
2. **Matriz de Análisis de Riesgo:**

Decisión	**H0 es Verdadera**	**H0 es Falsa**
Rechazar H_0	**Error Tipo I ($\alpha = 0.05$):** Concluir que microservicios incrementa la latencia cuando no es así. **Costo:** Pérdida financiera por rediseñar la arquitectura o descartar microservicios innecesariamente.	**Decisión Correcta ($1 - \beta$):** Se detecta la diferencia real de latencias.

Decisión	H0 es Verdadera	H0 es Falsa
No Rechazar H_0	**Decisión Correcta** $(1-\alpha)$**:** Se mantiene la arquitectura sin cambios infundados.	**Error Tipo II** (β)**:** Ignorar el incremento de latencia. **Costo:** Degradación inadvertida en producción y caída de SLAs con clientes.

3. **Resultados de la Prueba t de Student/Welch:**
    - **Nivel de significancia (α):** 0.05
    - **Estadístico t calculado:** -2.48
    - p-value**:** 0.0135
4. **Veredicto y Recomendación Técnica:**
    - **Veredicto:** Como p-value$(0.0135) < \alpha(0.05)$, **se RECHAZA la hipótesis nula (H_0).**
    - **Recomendación Técnica de Ingeniería:** Existe evidencia estadística suficiente para afirmar que la arquitectura de Microservicios introduce una sobrecarga significativa en la latencia de respuesta HTTP. Se recomienda evaluar patrones de optimización de comunicación (como protocolo gRPC sobre HTTP/2, uso de cachés distribuidas o API Gateways optimizados) antes de migrar componentes críticos a microservicios.

5. CONCLUSIONES

- Las técnicas inferenciales permitieron sustentar una decisión tecnológica basada en datos empíricos y rigurosidad estadística.
- El estudio confirma la ventaja operativa del Monolito en entornos donde la latencia mínima es un parámetro crítico de rendimiento.